

ΜΥΕ041

Διαχείριση Σύνθετων Δεδομένων


Διδάσκων: Ν. Μαμουλής

Εργασία: 1ο Σετ Ασκήσεων -
ΑΣΚΗΣΗ 1 (Ιστογράμματα)

Ομάδα:

Παναγιώτης Παρασκευόπουλος ΑΜ: 2905

Άγγελος Μπεζαΐτης ΑΜ: 4432



Περιεχόμενα

Εισαγωγή.....	2
Προγραμματιστική Υλοποίηση.....	3
Δημιουργία Ιστογραμμάτων (1.1_histograms.py)	3
Εκτιμητής Ερωτημάτων (1.2_estimator.py)	3
Βασικές Συναρτήσεις και Αλγοριθμική Λογική	4
Α) Εύρεση Ορίων στο Equi-Depth Histogram.....	4
Β) Υπολογισμός Επικάλυψης (Overlap Ratio)	4
Πειραματική Αξιολόγηση.....	5
Συμπεράσματα.....	5
Οδηγίες Εκτέλεσης (How to Run)	6

Εισαγωγή

Σε συστήματα βάσεων δεδομένων, τα ιστογράμματα χρησιμοποιούνται για την προσεγγιστική αναπαράσταση της κατανομής των τιμών στα πεδία των πινάκων. Βοηθούν το σύστημα να υπολογίσει γρήγορα πόσα αποτελέσματα θα βγάλει μια αναζήτηση (όπως ένα φιλτράρισμα), ώστε να βρει τον πιο γρήγορο δρόμο για να την εκτελέσει. Στα πλαίσια αυτής της άσκησης, κληθήκαμε να δημιουργήσουμε και να συγκρίνουμε δύο βασικούς τύπους ιστογραμμάτων για το γνώρισμα Age από το δοθέν σύνολο δεδομένων `final_general.dat`.

Equi-width Histogram: Ο χώρος των τιμών χωρίζεται σε διαστήματα (bins) που έχουν ακριβώς το ίδιο εύρος τιμών. Σε κάθε bin αποθηκεύεται το πλήθος των εγγραφών (συχνότητα) που εμπίπτουν σε αυτό το εύρος. Η αναπαράστασή του είναι ένα διάνυσμα συχνοτήτων.

Equi-depth Histogram: Τα όρια των διαστημάτων αναπροσαρμόζονται ώστε το πλήθος των εγγραφών που πέφτει σε κάθε bin να είναι σταθερό (ίδιο άθροισμα δεδομένων). Συνεπώς, το πλάτος των bins ποικίλλει. Η αναπαράστασή του είναι ένα διάνυσμα ορίων.

Προγραμματιστική Υλοποίηση

Η άσκηση υλοποιήθηκε σε γλώσσα Python και χωρίζεται σε δύο βασικά αυτόνομα προγράμματα, προσομοιώνοντας τη λειτουργία ενός συστήματος βάσεων δεδομένων: τη δημιουργία των στατιστικών και τη χρήση τους για εκτίμηση.

Δημιουργία Ιστογραμμάτων (1.1_histograms.py)

Το πρόγραμμα διαβάζει το αρχείο δεδομένων και απομονώνει τη 2η στήλη (Age), προσπερνώντας κενές ή μη έγκυρες τιμές. Στη συνέχεια δημιουργεί δύο ιστογράμματα των 10 bins.

Για το equi-width, υπολογίζεται το σταθερό πλάτος με τον τύπο $W = \frac{Max - Min}{10}$ και τα δεδομένα κατανέμονται μέσω μαθηματικού υπολογισμού του δείκτη (Index).

Για το equi-depth, τα δεδομένα ταξινομούνται αλγοριθμικά και η λίστα χωρίζεται σε 10 ίσα τμήματα, κρατώντας τις τιμές στα σημεία που "κόπηκαν" ως τα νέα όρια. Στο τέλος, όλες αυτές οι πληροφορίες αποθηκεύονται σε ένα εξωτερικό αρχείο κειμένου (`histograms_output.txt`).

Εκτιμητής Ερωτημάτων (1.2_estimator.py)

Το δεύτερο πρόγραμμα δέχεται ως ορίσματα γραμμής εντολών τα όρια αναζήτησης “α” και “β”. Για την εκτίμηση του πλήθους των αποτελεσμάτων της συνθήκης $\alpha \leq Age \leq \beta$, υλοποιήθηκε συνάρτηση που υπολογίζει το ποσοστό επικάλυψης του διαστήματος αναζήτησης με το μέγεθος του κάθε bin. Αν το ζητούμενο διάστημα καλύπτει π.χ. το 30% ενός bin, υποθέτουμε ότι το 30% των εγγραφών του bin αποτελούν μέρος του αποτελέσματος. Το πρόγραμμα υπολογίζει τις δύο εκτιμήσεις και, διαβάζοντας ξανά τα αρχικά δεδομένα, μετράει το πραγματικό αποτέλεσμα.

Βασικές Συναρτήσεις και Αλγοριθμική Λογική

Για την υλοποίηση της άσκησης, αναπτύχθηκαν συγκεκριμένες συναρτήσεις που αποτυπώνουν τη θεωρία των ιστογραμμάτων σε κώδικα.

A) Εύρεση Ορίων στο Equi-Depth Histogram

Σε αντίθεση με το equi-width όπου ο υπολογισμός γίνεται με βάση την τιμή, στο equi-depth πρέπει να εξασφαλίσουμε ότι κάθε bin έχει το ίδιο πλήθος εγγραφών.

```
def create_equi_depth_histogram(ages, num_bins=10):
    sorted_ages = sorted(ages)
    total_elements = len(sorted_ages)
    elements_per_bin = total_elements / num_bins

    boundaries = [sorted_ages[0]]
    for i in range(1, num_bins):
        cut_index = int(i * elements_per_bin)
        boundaries.append(sorted_ages[cut_index])
    boundaries.append(sorted_ages[-1])

    return boundaries
```

Αρχικά, είναι απαραίτητη η ταξινόμηση των δεδομένων (sorted), η οποία αποτελεί και το πιο απαιτητικό υπολογιστικά βήμα. Στη συνέχεια, βρίσκουμε το ιδανικό πλήθος στοιχείων ανά bin (elements_per_bin). Ο βρόχος for διατρέπει τα επιθυμητά "κοψίματα" (cuts) της λίστας, εξάγοντας την τιμή της ηλικίας που βρίσκεται στο εκάστοτε index, δημιουργώντας έτσι τα μεταβλητά όρια (boundaries) του ιστογράμματος.

B) Υπολογισμός Επικάλυψης (Overlap Ratio)

Η σημαντικότερη συνάρτηση του **1.2_estimator.py**, η οποία αναλαμβάνει να υλοποιήσει την εκτίμηση όταν τα όρια του ερωτήματος δεν ταυτίζονται με τα όρια των bins.

```
def calculate_overlap_ratio(alpha, beta, bin_start, bin_end):  
    """Υπολογίζει τι ποσοστό του bin [bin_start, bin_end) καλύπτεται από το  
    [alpha, beta]"""  
    overlap_start = max(alpha, bin_start)  
    overlap_end = min(beta, bin_end)  
    overlap_length = max(0, overlap_end - overlap_start)  
  
    bin_length = bin_end - bin_start  
    if bin_length == 0:  
        return 0  
    return overlap_length / bin_length
```

Η συνάρτηση βρίσκει τη τομή δύο διαστημάτων: του εύρους του bin [bin_start, bin_end) και του ερωτήματος [alpha, beta]. Το σημείο έναρξης της επικάλυψης είναι το μέγιστο των δύο αρχικών ορίων, ενώ το σημείο λήξης είναι το ελάχιστο των δύο τελικών. Η χρήση της `max(0, ...)` διασφαλίζει ότι αν τα διαστήματα δεν τέμνονται, το μήκος δεν θα είναι αρνητικό. Τέλος, επιστρέφεται το ποσοστό επικάλυψης, το οποίο πολλαπλασιάζεται με τη συχνότητα του bin για την τελική εκτίμηση.

Πειραματική Αξιολόγηση

Εκτελέστηκαν πολλαπλά πειράματα για να ελεγχθεί η ακρίβεια των δύο ιστογραμμάτων σε διαφορετικές περιοχές της κατανομής.

Πείραμα 1 - Πυκνή Περιοχή (25 ≤ Age ≤ 40):

Πραγματικό: 4028 | Equi-Width: 3792.88 | Equi-Depth: 3890.04

Το Equi-Depth πλησίασε πολύ περισσότερο το πραγματικό αποτέλεσμα (μικρότερο σφάλμα).

Πείραμα 2 - Αραιή Περιοχή / Ουρά (60 ≤ Age ≤ 80):

Πραγματικό: 545 | Equi-Width: 585.50 | Equi-Depth: 777.23

Το Equi-Width είχε πολύ καλύτερη προσέγγιση, με το Equi-Depth να κάνει σημαντική υπερεκτίμηση.

Πείραμα 3 - Μεγάλο Εύρος (10 ≤ Age ≤ 80):

Πραγματικό: 9654 | Equi-Width: 9626.00 | Equi-Depth: 9542.67

Και τα δύο τα πήγαν καλά, αλλά το Equi-Width είχε ελαφρώς μικρότερο σφάλμα λόγω αλληλοαναίρεσης θετικών και αρνητικών σφαλμάτων σε ενδιάμεσα bins.

Συμπεράσματα

Μέσω του πειραματισμού, γίνεται σαφές ότι η απόδοση των ιστογραμμάτων εξαρτάται άμεσα από τη μορφή της κατανομής των δεδομένων.

Το Equi-depth histogram υπερτερεί γενικά στο συγκεκριμένο σύνολο δεδομένων. Τα δεδομένα ηλικίας ακολουθούν ασύμμετρη κατανομή με μεγάλη συγκέντρωση στις ηλικίες 20-40. Επειδή το equi-depth προσαρμόζει τα όριά του, διαθέτει "στενά" bins σε αυτές τις περιοχές, προσφέροντας υψηλή ανάλυση και ακρίβεια εκεί που βρίσκεται ο κύριος όγκος της πληροφορίας.

Αντίθετα, το Equi-width histogram υπερτερεί στις αραιοκατοικημένες "ουρές" της κατανομής (π.χ. ηλικίες > 60). Το equi-depth αναγκάζεται να φτιάξει υπερβολικά μεγάλα bins για να συγκεντρώσει τον απαιτούμενο σταθερό αριθμό εγγραφών, χάνοντας εντελώς την ακρίβεια, ενώ το equi-width διατηρεί σταθερά διαστήματα, αποτυπώνοντας καλύτερα την αραιή κατανομή.

Το Equi-width στηρίζεται στην υπόθεση της ομοιόμορφης κατανομής μέσα στα bins, κάτι που αποτυγχάνει σε ασύμμετρα δεδομένα, αλλά μπορεί να δώσει καλά αποτελέσματα σε ερωτήματα μεγάλου εύρους λόγω αλληλοαναίρεσης του σφάλματος.

Οδηγίες Εκτέλεσης (How to Run)

Ο κώδικας έχει γραφτεί σε καθαρή Python 3 και δεν απαιτεί καμία εγκατάσταση εξωτερικών βιβλιοθηκών.

Προαπαιτούμενα: Βεβαιωθείτε ότι τα αρχεία του κώδικα (*1.1_histograms.py* και *1.2_estimator.py*) καθώς και το αποσυμπιεσμένο αρχείο δεδομένων (*final_general.dat*) βρίσκονται στον ίδιο κατάλογο.

Βήμα 1: Δημιουργία Ιστογραμμάτων

Ανοίξτε το τερματικό, πλοηγηθείτε στον φάκελο της εργασίας και εκτελέστε την παρακάτω εντολή:

```
python 1.1_histograms.py
```

Το πρόγραμμα θα διαβάσει τα δεδομένα, θα τυπώσει στο τερματικό τα ραβδογράμματα των δύο ιστογραμμάτων σε μορφή ASCII και θα δημιουργήσει αυτόματα το αρχείο `histograms_output.txt`

Βήμα 2: Εκτέλεση Εκτιμητή Ερωτημάτων

Αφού δημιουργηθεί το αρχείο *histograms_output.txt*, μπορείτε να τρέξετε τον εκτιμητή περνώντας τα όρια “α” και “β” απευθείας ως ορίσματα γραμμής εντολών. Η σύνταξη είναι η εξής:

python 1.2_estimator.py <α> <β>

Παράδειγμα εκτέλεσης για την αναζήτηση ατόμων με ηλικία από 25 έως 40 ετών:

python 1.2_estimator.py 25 40

Το πρόγραμμα θα διαβάσει τα μεταδεδομένα, θα υπολογίσει την επικάλυψη, θα σαρώσει τα αρχικά δεδομένα για το πραγματικό αποτέλεσμα και θα τυπώσει τον συγκριτικό πίνακα με τα σφάλματα της κάθε μεθόδου.